

UNIVERSIDADE FEDERAL DE GOIÁS (UFG)

PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO (PPGCC)

ALEX FERREIRA DE ALMEIDA

**GERAÇÃO AUMENTADA POR RECUPERAÇÃO APLICADA A BASES DE CÓDIGO DE
SOFTWARE: UM ESTUDO DE MAPEAMENTO SISTEMÁTICO**

Protocolo de pesquisa criado para subsidiar a elaboração de um artigo científico para disciplina de Engenharia de Software do PPGCC da UFG.

Professor Orientador: Dr. Valdemar Vicente Graciano Neto.

INTRODUÇÃO

Este estudo consiste em um Mapeamento Sistemático de Literatura (MSL). A condução deste trabalho segue estritamente as diretrizes e o framework propostos por Petersen et al. (2015), projetados para estruturar, categorizar e quantificar visualmente o estado da arte de um determinado campo de conhecimento. O processo é executado em cinco etapas sequenciais: 1) definição das questões de pesquisa; 2) condução da busca por estudos primários em bases de dados eletrônicas; 3) triagem dos estudos por meio da aplicação de critérios explícitos de inclusão e exclusão; 4) desenvolvimento de um esquema de classificação baseado em palavras-chave (*keywording*); e 5) extração de dados e mapeamento sistemático dos resultados.

Para a estruturação rigorosa das questões de pesquisa e a identificação precisa das palavras-chave que compõem a string de busca adota-se o framework PICOC (acrônimo para Population, Intervention, Comparison, Outcome, and Context). Integrado formalmente à Engenharia de Software por Kitchenham e Charters (2007), essa estrutura estende os modelos tradicionais de revisão ao decompor o escopo da investigação em cinco dimensões fundamentais: 1) População (P), que delimita o grupo de interesse, papel ou área afetada; 2) Intervenção (I), correspondente à tecnologia, ferramenta ou metodologia específica sob análise; 3) Comparação (C), que identifica a alternativa ou estado atual com o qual a intervenção é contrastada; 4) Resultado (Outcome - O), que define os efeitos, benefícios ou métricas de interesse a serem medidos; e 5) Contexto (C), que especifica o ambiente ou cenário no qual a investigação se insere, delimitando o escopo da pesquisa em termos de domínio, tipo de estudo ou período considerado.

Para garantir a transparência, o rigor e a reprodutibilidade visual no processo de seleção dos estudos primários, adota-se o fluxograma PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses). Embora originado como uma diretriz de relato em outras ciências, o modelo de fluxo de quatro fases do PRISMA é integrado a este estudo de forma complementar e adaptada às práticas de revisão de Kitchenham e Charters (2007) e de mapeamento de Petersen et al. (2015). O diagrama documenta de forma rastreável o funil de dados da pesquisa por meio de quatro etapas principais: 1) Identificação, que contabiliza os registros brutos localizados nas bases de dados eletrônicas após a remoção de duplicatas; 2) Triagem (Screening), que mapeia a exclusão inicial com base na leitura de títulos e resumos; 3) Elegibilidade, que quantifica os artigos avaliados na íntegra a partir dos critérios de inclusão e exclusão; e 4) Inclusão, que consolida o número final de estudos primários selecionados para o mapeamento. O uso do diagrama mitiga vieses de publicação e facilita a auditoria externa do processo de refinamento amostral.

Para a definição estruturada e alinhamento do escopo deste estudo, adota-se a abordagem Goal-Question-Metric (GQM), desenvolvida originalmente por Basili e Weiss (1984) e consolidada por Basili (1992). O GQM é um paradigma de medição orientado a objetivos que estabelece uma estrutura hierárquica dividida em três níveis: 1) Conceitual (Goal), onde se define o objetivo principal da investigação sob uma perspectiva e contexto específicos; 2) Operacional (Question), no qual o objetivo é refinado em um conjunto de questões que caracterizam o objeto de estudo de forma quantificável; e 3) Quantitativo (Metric), onde são associadas as métricas de dados necessárias para responder satisfatoriamente a cada questão formulada. No âmbito deste protocolo, a aplicação do framework GQM garante que a coleta e a análise das evidências da literatura estejam rigorosamente vinculadas às metas centrais da pesquisa, evitando a inclusão de métricas ad-hoc ou desconexas do propósito científico.

1. OBJETIVO GQM

Analisar abordagens de Retrieval-Augmented Generation (RAG)

baseadas em Large Language Models (LLMs)

aplicadas a codebases de software

com o propósito de identificar e classificar suas técnicas, LLMs empregadas,

linguagens de programação e tipos de sistemas estudados,

métricas de avaliação e lacunas existentes

do ponto de vista de pesquisadores e praticantes de Engenharia de Software

no contexto de estudos primários publicados entre 2020 e 2026.

2. QUESTÕES DE PESQUISA

- RQ1: Quais técnicas e arquiteturas de RAG são propostas para aplicação em codebases de software?

Rationale: Identificar e classificar as arquiteturas existentes: permite consolidar o estado da arte quanto às estratégias de recuperação e processamento de código, servindo de base para as demais questões do mapeamento.

- RQ2: Quais Large Language Models são empregadas como componente gerador nas abordagens de RAG para codebases?

Rationale: Compreender quais LLMs são predominantemente adotadas auxilia pesquisadores e praticantes na seleção de modelos adequados para implementações futuras, além de revelar tendências de adoção na área.

- RQ3: Quais linguagens de programação e tipos de sistemas são mais estudados?

Rationale: Conhecer o escopo das linguagens e sistemas investigados evidencia o alcance das abordagens propostas e possíveis vieses de cobertura na literatura.

- RQ4: Quais métricas são utilizadas para avaliar a efetividade das abordagens de RAG em codebases?

Rationale: Mapear as métricas utilizadas permite avaliar o rigor dos estudos e identificar padrões de avaliação que possam orientar trabalhos futuros.

- RQ5: Quais são as principais lacunas identificadas na literatura sobre RAG aplicado a codebases?

Rationale: Identificar lacunas contribui diretamente para a agenda de pesquisa da área, apontando oportunidades para estudos futuros.

3. PICOC

Elemento	Definição
P - População	Codebases de software: código-fonte e repositórios de código.
I - Intervenção	Abordagens de RAG baseadas em LLMs ou IA Generativa.
C - Comparação	Não se aplica. O mapeamento não pressupõe um grupo controle; o foco é catalogar o estado da arte, não comparar abordagens entre si.
O - Outcome (Resultado)	Técnicas e arquiteturas de RAG. LLMs empregadas. Linguagens de programação e tipos de sistemas estudados. Métricas de avaliação. Lacunas de pesquisa.
C - Contexto	Estudos primários com revisão por pares no domínio de Engenharia de Software, delimitado pelo foco em artefatos de código-fonte.

4. STRINGS DE BUSCA

("source code" OR "codebase" OR "code repository") AND
("Retrieval-Augmented Generation" OR "RAG") AND
("LLM" OR "Large Language Model" OR "GenAI" OR "Generative AI")

Observações:

- O "Resultado" não compõe a string pois representa o que será extraído dos estudos, não um critério de busca.
- O "Contexto" não compõe a string de busca pois é garantido pelos critérios de seleção: a delimitação ao domínio de Engenharia de Software é assegurada pelo CI1, e a exigência de revisão por pares é assegurada pelo CE5.
- Embora RAG e LLM componham conceitualmente a mesma Intervenção, eles são representados como dois grupos distintos conectados por AND na string de busca. Essa decisão é intencional: o AND garante que apenas estudos que tratam explicitamente da combinação RAG+LLM sejam recuperados, excluindo trabalhos sobre RAG sem base em modelos de linguagem de grande escala e trabalhos sobre LLMs aplicados a código sem componente de recuperação. Trata-se de uma escolha de precisão sobre sensibilidade. Está-se ciente de que artigos que referenciam modelos específicos (Ex.: GPT, Llama, Gemini, Claude, etc.) sem empregar os termos "LLM" ou "Large Language Model" podem não ser recuperados; para mitigar parcialmente esse risco, o termo "Generative AI" foi incluído como hiperônimo de uso corrente na literatura, aumentando a chance de cobertura indireta desses modelos. Essa decisão é documentada aqui para fins de rastreabilidade e reprodutibilidade da busca.

5. BASES

Base	URL	Justificativa
ACM Digital Library	https://dl.acm.org/	Principal repositório de publicações da Association for Computing Machinery (ACM), com cobertura abrangente de Engenharia de Software e áreas correlatas. Indexa venues de alto impacto como ESEC/FSE, ISSTA, ICSE (co-publicada com IEEE) e periódicos como TOSEM e CACM. Oferece busca avançada com operadores booleanos e exportação estruturada em BibTeX - fundamentais para a condução sistemática e reproduzível da busca.
IEEE Xplore	https://ieeexplore.ieee.org/	Principal repositório de publicações IEEE e IET em Engenharia de Software, Computação e áreas afins. Indexa conferências de alto impacto como ICSE, ASE, SANER e MSR, além dos principais periódicos da área (e.g., IEEE TSE, IEEE Software). Oferece busca avançada com exportação em CSV/BibTeX.
Scopus	https://www.scopus.com/	Base multidisciplinar da Elsevier com ampla cobertura de Engenharia de Software, incluindo publicações ACM, Springer e Elsevier. Possui índice de citações e ferramentas de análise bibliométrica, além de suporte a exportação estruturada — fundamentais para a condução sistemática e reproduzível da busca.

Observação: As bases selecionadas apresentam sobreposição intencional de cobertura. O Scopus indexa publicações da ACM e do IEEE, podendo duplicar resultados já retornados pela ACM Digital Library e pelo IEEE Xplore. Adicionalmente, alguns venues são co-publicados por mais de uma editora (notadamente o ICSE, co-publicado pela ACM e pelo IEEE). Eventuais duplicatas resultantes da busca em múltiplas bases serão identificadas e tratadas conforme o critério CE3.

6. CRITÉRIOS

Definição formal dos critérios de inclusão e exclusão dos artigos:

6.1. Inclusão

ID	Critério
CI1	O artigo propõe, implementa ou avalia empiricamente uma abordagem de RAG baseada em LLM cujo foco principal seja a aplicação a artefatos de código-fonte (código de produção, documentação técnica gerada a partir de código, testes automatizados, scripts de infraestrutura ou queries de banco de dados).

6.2. Exclusão

ID	Critério
CE1	O artigo não satisfaz o critério de inclusão CI1.
CE2	Não redigido em língua inglesa.
CE3	Artigo duplicado: em caso de mesmo trabalho em múltiplos venues, manter apenas a versão publicada com revisão por pares; se ambas forem revisadas, manter a mais completa.
CE4	Artigo sem abstract disponível para leitura.
CE5	Literatura cinzenta: preprints, relatórios técnicos, whitepapers, posts e artigos sem revisão por pares formal.
CE6	Publicado fora do período de janeiro de 2020 a abril de 2026.

Observação: Quando houver dúvida entre incluir ou excluir um artigo, a prática padrão em MSL é incluir na dúvida durante a triagem por título/abstract, e só excluir com certeza na leitura do texto completo. Isso evita descartar artigos relevantes prematuramente (reduz viés de exclusão).

7. PRISMA

A busca inicial nas bases de dados eletrônicas retornou um total de 140 registros brutos, distribuídos entre Scopus (n = 77), IEEE Xplore (n = 51) e ACM Digital Library (n = 12). Para dar suporte ao gerenciamento e à seleção desses estudos, os metadados (.bib) foram importados para a plataforma Rayyan (OUZZANI et al., 2016). Por meio das funcionalidades da ferramenta, foi executado o processo automatizado de detecção de similaridade, resultando na identificação e remoção de 32 registros duplicados, restando 108 artigos únicos para a etapa de triagem. Na sequência, realizou-se a análise preliminar de títulos e resumos dentro da plataforma, o que levou à exclusão de 58 estudos que não atendiam aos critérios de elegibilidade. Ao final desse funil de seleção, 50 estudos primários foram integralmente incluídos para a extração de dados e composição do mapeamento sistemático.

7.1. Organização dos dados no fluxo PRISMA

- **Identificação (Total Bruto):** 140 registros importados.
 - *IEEE Xplore:* 51
 - *Scopus:* 77
 - *ACM:* 12
- **Remoção de Duplicatas:** 32 registros deletados ($140 - 32 = 108$).
- **Triagem (Screening):** 108 artigos avaliados (título/resumo).
- **Excluídos na Triagem:** 58 artigos.
- **Adicionados (Elegíveis / Amostra Final):** 50 artigos restantes ($108 - 58 = 50$).

REFERÊNCIAS

BASIL, Victor R.. Software Modeling and Measurement: The Goal/Question/Metric Paradigm. **Institute for Advanced Computer Studies**, Department of Computer Science, University of Maryland, 1992.

BASIL, Victor; WEISS, David M.. A Methodology for Collecting Valid Software Engineering Data. **IEEE Transactions on Software Engineering**, v. SE-10, n. 6, p. 728-738, 1984.

KITCHENHAM, Barbara; CHARTERS, Stuart. Guidelines for performing Systematic Literature Reviews in Software Engineering. **EBSE Technical Report EBSE-2007-01**, Keele University, v. 2.3, 2007.

OUZZANI, Mourad et al. Rayyan – a web and mobile app for systematic reviews. **Systematic Reviews**, 2016.

PETERSEN, Kai et al. Guidelines for conducting systematic mapping studies in software engineering: An update. **Information and Software Technology**, v. 64, p. 1-18, 2015.