

Engenharia de Software

Prof. Dr. Valdemar Vicente Graciano Neto

Discentes: Alex Almeida e Paulo Augusto

Protocolo de Pesquisa

1. Título

Geração Aumentada por Recuperação Aplicada a Bases de Código de Software: Um Estudo de Mapeamento Sistemático (Retrieval-Augmented Generation Applied to Software Codebases: A Systematic Mapping Study)

2. Objetivo GQM

Analisar abordagens de Retrieval-Augmented Generation (RAG) baseadas em Large Language Models (LLMs) aplicadas a codebases de software com o propósito de identificar e classificar com respeito a técnicas utilizadas, LLMs empregadas, linguagens/sistemas estudados, métricas de avaliação e lacunas existentes do ponto de vista de pesquisadores e praticantes de Engenharia de Software no contexto de estudos primários publicados entre 2020 e 2026

3. Método

Mapeamento Sistemático da Literatura (MSL), seguindo as diretrizes de Kitchenham & Charters (2007) e Petersen et al. (2015):
Guidelines for performing Systematic Literature Reviews in Software Engineering, 2007.
Guidelines for Conducting Systematic Mapping Studies in Software Engineering: An Update, 2015.

4. Strings de Busca

("Retrieval-Augmented Generation" OR "RAG") AND
("source code" OR "codebase" OR "code repository") AND
("LLM" OR "Large Language Model" OR "GenAI" OR "Generative AI")

5. Questões de Pesquisa (RQs)

- RQ1: Quais técnicas e arquiteturas de RAG são propostas para aplicação em codebases de software?

Rationale: Identificar e classificar as arquiteturas existentes permite consolidar o estado da arte quanto às estratégias de recuperação e processamento de código, servindo de base para as demais questões do mapeamento.

- RQ2: Quais Large Language Models são empregadas como componente gerador nas abordagens de RAG para codebases?

Rationale: Compreender quais LLMs são predominantemente adotadas auxilia pesquisadores e praticantes na seleção de modelos adequados para implementações futuras, além de revelar tendências de adoção na área.

- RQ3: Quais linguagens de programação e tipos de sistemas são mais estudados?

Rationale: Conhecer o escopo das linguagens e sistemas investigados evidencia o alcance das abordagens propostas e possíveis vieses de cobertura na literatura.

- RQ4: Quais métricas são utilizadas para avaliar a efetividade das abordagens de RAG em codebases?

Rationale: Mapear as métricas utilizadas permite avaliar o rigor dos estudos e identificar padrões de avaliação que possam orientar trabalhos futuros.

- RQ5: Quais são as principais lacunas identificadas na literatura sobre RAG aplicado a codebases?

Rationale: Identificar lacunas contribui diretamente para a agenda de pesquisa da área, apontando oportunidades para estudos futuros.

6. Fontes

- IEEE Xplore
- ACM Digital Library
- Scopus