

Engenharia de Software

Prof. Dr. Valdemar Vicente Graciano Neto

Discentes: Alex Almeida e Paulo Augusto

Protocolo de Pesquisa

1. Título

Geração Aumentada por Recuperação Aplicada a Bases de Código de Software: Um Estudo de Mapeamento Sistemático (Retrieval-Augmented Generation Applied to Software Codebases: A Systematic Mapping Study)

2. Objetivo GQM (Goal Question Metric)

Analisar abordagens de Retrieval-Augmented Generation (RAG) baseadas em Large Language Models (LLMs) aplicadas a codebases de software com o propósito de identificar e classificar suas técnicas, LLMs empregadas, linguagens/sistemas estudados, métricas de avaliação e lacunas existentes do ponto de vista de pesquisadores e praticantes de Engenharia de Software no contexto de estudos primários publicados entre 2020 e 2026.

3. Método

Mapeamento Sistemático da Literatura (MSL), seguindo as diretrizes de Kitchenham & Charters (2007) e Petersen et al. (2015):
Guidelines for performing Systematic Literature Reviews in Software Engineering, 2007.
Guidelines for Conducting Systematic Mapping Studies in Software Engineering: An Update, 2015.

4. Strings de Busca

("Retrieval-Augmented Generation" OR "RAG") AND
("source code" OR "codebase" OR "code repository") AND
("LLM" OR "Large Language Model" OR "GenAI" OR "Generative AI")

5. Questões de Pesquisa (RQs)

- RQ1: Quais técnicas e arquiteturas de RAG são propostas para aplicação em codebases de software?

Rationale: Identificar e classificar as arquiteturas existentes: permite consolidar o estado da arte quanto às estratégias de recuperação e processamento de código, servindo de base para as demais questões do mapeamento.

- RQ2: Quais Large Language Models são empregadas como componente gerador nas abordagens de RAG para codebases?

Rationale: Compreender quais LLMs são predominantemente adotadas auxilia pesquisadores e praticantes na seleção de modelos adequados para implementações futuras, além de revelar tendências de adoção na área.

- RQ3: Quais linguagens de programação e tipos de sistemas são mais estudados?

Rationale: Conhecer o escopo das linguagens e sistemas investigados evidencia o alcance das abordagens propostas e possíveis vieses de cobertura na literatura.

- RQ4: Quais métricas são utilizadas para avaliar a efetividade das abordagens de RAG em codebases?

Rationale: Mapear as métricas utilizadas permite avaliar o rigor dos estudos e identificar padrões de avaliação que possam orientar trabalhos futuros.

- RQ5: Quais são as principais lacunas identificadas na literatura sobre RAG aplicado a codebases?

Rationale: Identificar lacunas contribui diretamente para a agenda de pesquisa da área, apontando oportunidades para estudos futuros.

6. Fontes

- IEEE Xplore (<https://ieeexplore.ieee.org/>)

- Scopus (<https://www.scopus.com/>)

Observação: A ACM Digital Library (<https://dl.acm.org/>) foi inicialmente prevista como fonte de busca. Porém, foi removida do protocolo devido a restrições de acesso às funcionalidades de busca avançada e exportação estruturada na Basic Edition, inviabilizando a condução sistemática e reproduzível da busca nessa base. A cobertura da literatura é mantida pelas bases IEEE Xplore e Scopus, que indexam os principais venues de Engenharia de Software, incluindo publicações originalmente indexadas pela ACM.

7. Critérios

Definição formal dos critérios de inclusão e exclusão dos artigos:

7.1. Inclusão

ID	Critério
CI1	O artigo propõe, implementa ou avalia empiricamente uma abordagem de RAG baseada em LLM.
CI2	A abordagem de RAG é aplicada diretamente a artefatos de código-fonte (código de produção, documentação técnica gerada a partir de código, testes automatizados, scripts de infraestrutura ou queries de banco de dados).
CI3	Publicado entre janeiro de 2020 e abril de 2026. O filtro de período (2020-2026) é aplicado diretamente nas interfaces de busca das fontes.
CI4	Redigido em língua inglesa.
CI5	Publicado em venue com revisão por pares (conference paper, journal article ou early access article).

7.2. Exclusão

ID	Critério
CE1	O objeto da recuperação RAG não é código-fonte de software. Ex.: textos clínicos, documentos legais, artigos científicos, documentação não-técnica. Nota: documentação técnica gerada diretamente a partir de código-fonte (Ex.: Javadoc, docstrings) não se enquadra neste critério de exclusão.
CE2	O artigo utiliza LLM para tarefas de código sem componente de recuperação: o RAG não é central na abordagem.
CE3	Artigo duplicado: em caso de mesmo trabalho em múltiplos venues, manter apenas a versão publicada com revisão por pares; se ambas forem revisadas, manter a mais completa.
CE4	Artigo sem abstract disponível para leitura.
CE5	Literatura cinzenta: preprints, relatórios técnicos, whitepapers, posts e artigos sem revisão por pares formal.

Observação: Quando houver dúvida entre incluir ou excluir um artigo, a prática padrão em MSL é incluir na dúvida durante a triagem por título/abstract, e só excluir com certeza na leitura do texto completo. Isso evita descartar artigos relevantes prematuramente (reduz viés de exclusão).